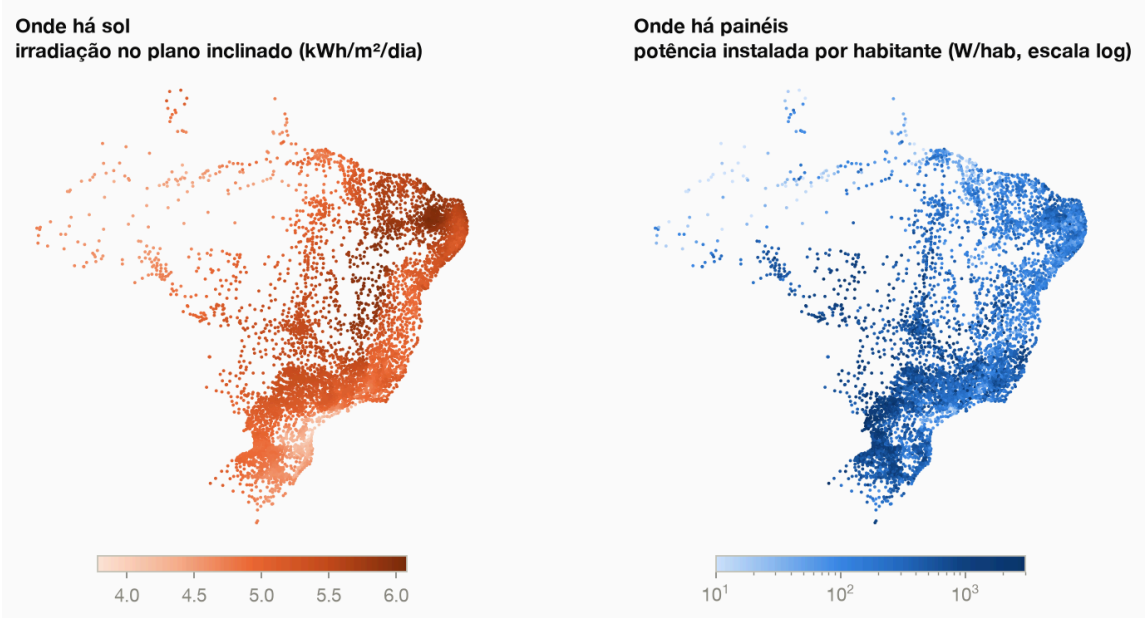
GLOBAL SOLUTION 2026.2 · BIG DATA & ANALYTICS

CitizenTech: onde o sol não vira painel

Energia solar distribuída no Brasil: quem está ficando de fora da transição energética



Aluno: Anderson Huang

RM: 565920

Tema: Sustentabilidade

Repositório: https://github.com/andhuangg/gs-energia-solar

Aluno: Anderson Huang · **RM:** 565920 · **Disciplina:** Big Data & Analytics (Global Solution 2026.2) · **Tema:** Sustentabilidade

Pipeline de Big Data & Analytics que cruza 4,7 milhões de instalações solares registradas na ANEEL com dados de irradiação solar do INPE, tarifas de energia e dados socioeconômicos do IBGE para responder a uma pergunta: **a energia solar está chegando onde o sol é mais forte e onde a conta de luz mais pesa, ou apenas onde há renda?**

Entregável	Onde está
Investigação do problema	seção 1
Catálogo de dados	seção 2
Arquitetura da solução	seção 3 e `docs/img/00_arquitetura.png`
Pipeline implementado	`pipeline/` e seção 4
Feature Engineering	seção 5
Camada analítica	`data/gold/` e seção 6
Análises	seção 7
Dashboard	`docs/dashboard.html` e seção 8
Experimentação Spark	`databricks/` e seção 9
Relatório executivo	`relatorio_executivo.md`

> **Indo além do enunciado.** Como contribuição adicional, que não fazia parte dos entregáveis pedidos, o projeto também traz uma camada de **governança de dados no Unity Catalog**: dicionário de dados no próprio banco, tags de classificação e linhagem automática das tabelas. Veja a seção 11.

1. Investigação do problema

Problema. A micro e minigeração distribuída solar (painéis em telhados, fazendas solares de autoconsumo remoto) é a fonte de energia que mais cresce no Brasil: passou de 0,4 GW conectados em 2018 para 54,6 GW em 2026. O consumidor que instala painéis reduz a conta de luz por décadas. A pergunta é **quem está capturando esse benefício**. Se a adoção depende de renda e não do potencial solar, a transição energética amplia desigualdades: regiões e famílias de menor renda continuam pagando tarifas cheias enquanto subsidiam, via tarifa, a rede usada por quem já gera a própria energia.

Quem é afetado.

- Famílias de baixa renda e municípios pobres, que gastam proporcionalmente mais com energia e têm menos acesso a crédito para investir em painéis.
- O Nordeste, que tem a maior irradiação solar do país e, portanto, o maior retorno por painel instalado.
- Gestores públicos (MME, ANEEL, governos estaduais, bancos públicos de fomento como BNB e Caixa) que desenham programas de crédito, habitação social e incentivo.

Dimensão analisada. A distribuição territorial (município, UF, região) da adoção solar e sua relação com potencial solar, renda, tarifa, tipo de moradia e porte do município, além da evolução no tempo (2012 a 2026).

Decisões que os dados podem melhorar.

1. Onde concentrar linhas de crédito e programas de energia solar para baixa renda.
2. Quais municípios estão abaixo do esperado para o seu perfil e merecem ação local (campanhas, cooperativas, geração compartilhada).
3. Em quais cidades a barreira é a moradia vertical (apartamentos), e não a renda, o que pede geração compartilhada em vez de telhado próprio.
4. Como acompanhar se a política está funcionando (indicadores e metas).

Informações necessárias. Onde estão os sistemas e de que tipo são (ANEEL), quanto sol cada município recebe (INPE), quanto custa a energia em cada distribuidora (ANEEL), e quantas pessoas, domicílios, apartamentos e qual a renda de cada município (IBGE).

Viabilidade. Todas as fontes são públicas, oficiais, gratuitas e acessíveis por download ou API. A ANEEL e o IBGE usam o mesmo código de município, o que permite integrar as bases com precisão.

2. Catálogo de dados

#	Fonte	Acesso	Volume	Atributos usados	Atualização
1	**ANEEL**, Relação de empreendimentos de geração distribuída	Parquet	4.735.908 linhas, 108 MB	código do empreendimento, município IBGE, distribuidora (CNPJ), classe de consumo, modalidade, porte, tipo de geração, potência (kW), data de atualização cadastral	mensal
2	**ANEEL**, Tarifas homologadas das distribuidoras	Parquet	657.709 linhas	CNPJ da distribuidora, subgrupo, classe, modalidade, vigência, TUSD e TE (R$/MWh)	a cada reajuste
3	**INPE/LABREN**, Atlas Brasileiro de Energia Solar 2017	CSV por sede municipal	5.569 municípios	nome, UF, latitude, longitude, irradiação média anual no plano inclinado (Wh/m²/dia)	estático (climatologia de 17 anos)
4	**IBGE**, Censo 2022, tabela 4714	API SIDRA	5.570 municípios	população residente, área	decenal
5	**IBGE**, Censo 2022, tabela 4712	API SIDRA	5.570 municípios	domicílios particulares permanentes ocupados	decenal
6	**IBGE**, Censo 2022, tabela 6326	API SIDRA	5.570 municípios	% de domicílios do tipo apartamento	decenal
7	**IBGE**, PIB dos Municípios 2023, tabela 5938	API SIDRA	5.570 municípios	PIB a preços correntes	anual
8	**IBGE**, API de Localidades	JSON	5.571 municípios	código, nome, UF, região, região intermediária	sob demanda

Por que essas fontes e como se combinam.

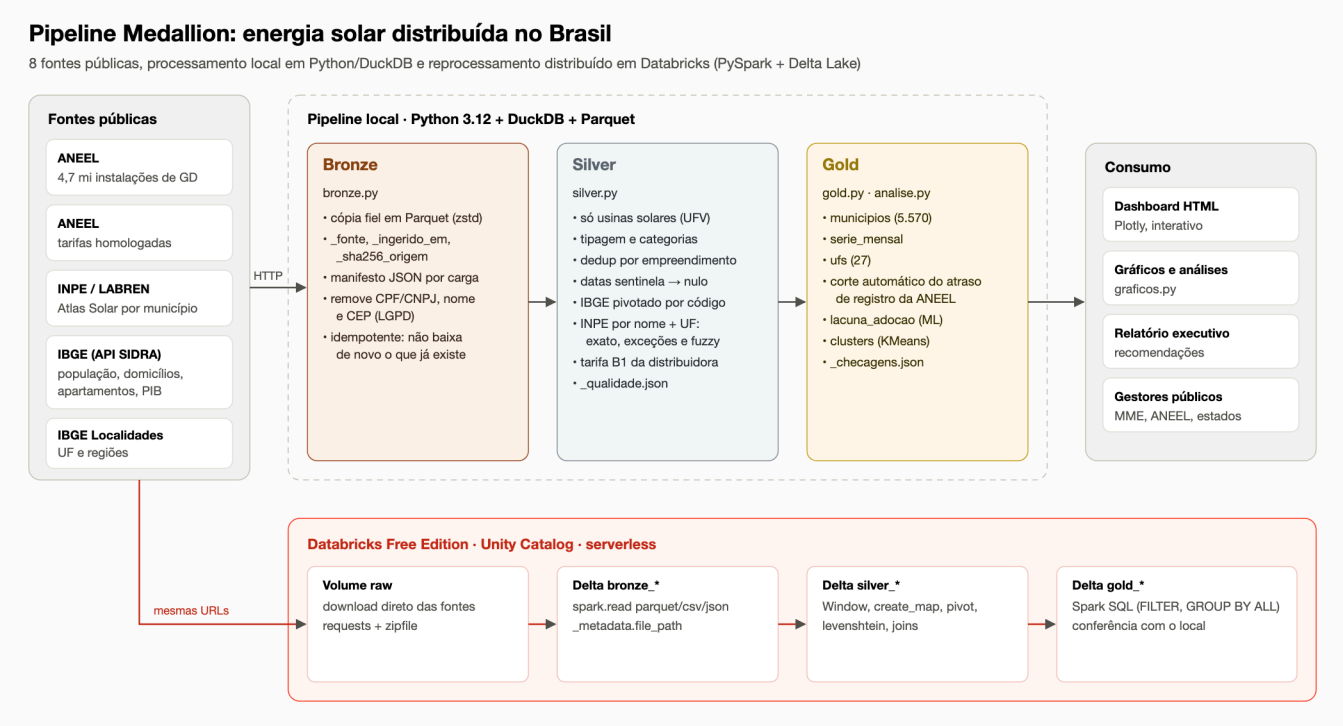
- A ANEEL é o registro oficial e completo de toda conexão de micro e minigeração no país (Resolução Normativa 1.000/2021). Sozinha, ela só diz onde há painéis.
- O Atlas Solar do INPE mede o **potencial**: quanto cada painel gera em cada lugar. É ele que permite dizer que uma adoção baixa é desperdício de potencial.
- A tarifa da ANEEL transforma geração em **dinheiro economizado** pelo consumidor.

- O IBGE normaliza tudo por população e domicílios e traz os fatores explicativos (renda, verticalização, porte).
- Chaves de integração: código IBGE do município (ANEEL e IBGE), CNPJ da distribuidora (geração distribuída e tarifas, 100% de correspondência) e nome + UF (INPE, que não tem código IBGE).

Confiabilidade e achados de qualidade.

- **Dados pessoais:** a base da ANEEL traz nome e CPF/CNPJ (parcialmente mascarado) do titular e CEP. Essas colunas são descartadas já na ingestão, porque a análise não precisa delas (princípio da minimização da LGPD).
- **Data de conexão:** a ANEEL publica a data da última atualização cadastral, que na prática coincide com a conexão para a grande maioria dos registros. 71 registros têm datas anteriores a 2009, 69 deles com o ano 1900 (valor sentinela), e a data vira nulo.
- **Atraso de registro:** os últimos meses da base aparecem incompletos (em setembro/2026 há 13 mil conexões contra uma média de 75 mil). O pipeline detecta isso automaticamente e só usa meses com pelo menos 80% da mediana dos 12 meses anteriores. O período estável vai até **maio/2026**.
- **Erro na fonte do INPE:** Porto Alegre aparece no arquivo do Atlas Solar com o estado "Rio Grande do Norte" (as coordenadas são do RS). Outros nomes mudaram desde 2017 (Campo Grande/RN era Augusto Severo, Assú era Açu). Foram tratados com uma tabela de exceções documentada no código.
- **Baixa renda subnotificada:** só 27 das 102 distribuidoras usam a classe "Residencial baixa renda" (REBR) no cadastro. O indicador de baixa renda existe na Gold, mas não foi usado em conclusões.

3. Arquitetura da solução



Camada	Conteúdo	Decisões técnicas
Pouso (`data/raw`)	arquivos originais como baixados	Preserva a fonte para auditoria e reprocessamento sem depender da disponibilidade dos portais.
Bronze (`data/bronze`)	uma tabela Parquet por fonte, fiel à origem	Parquet com compressão zstd (108 MB viram 38 MB). Colunas de linhagem `_fonte`, `_ingerido_em` e `_sha256_origem` em cada linha e um `_manifesto.json` por carga com URL, hash, linhas e colunas. Ingestão idempotente. Remoção de dados pessoais.
Silver (`data/silver`)	`instalacoes_solares` (4.734.997 linhas) e `municipios` (5.571 linhas)	SQL em DuckDB (motor colunar embarcado, processa os 4,7 milhões de linhas em segundos com pouca memória). Categorias padronizadas, deduplicação, integração das 8 fontes, relatório `_qualidade.json`.
Gold (`data/gold`)	`municipios`, `serie_mensal`, `ufs`, `lacuna_adocao`, `clusters`	Tabelas prontas para análise e dashboard. Inclui municípios sem nenhum sistema solar (necessário para taxas justas). Checagem de que a soma da Gold bate com a Silver (`_checagens.json`).

Por que essa stack. O volume (4,7 milhões de linhas) cabe em uma máquina, então o pipeline principal usa Python + DuckDB, que é simples de executar e reproduzir. A mesma lógica foi reimplementada em PySpark no Databricks (seção 9) para mostrar como o pipeline escala quando o volume não couber mais em uma máquina, por exemplo com o histórico mensal completo da ANEEL ou dados de medição horária.

Qualidade, rastreabilidade, atualização e confiabilidade.

- **Qualidade:** cada camada grava as contagens de entrada, descartes e correspondências (`_qualidade.json`, `_checagens.json`). O notebook do Databricks tem `assert` para duplicados e instalações sem município.
- **Rastreabilidade:** toda linha da Bronze sabe de qual URL e de qual arquivo (hash SHA-256) veio, e quando foi ingerida.
- **Atualização:** a ANEEL atualiza a base mensalmente. Rodar `bronze.py` com a opção de atualizar baixa a versão nova, e as demais etapas são determinísticas.
- **Confiabilidade:** a Silver e a Gold do Databricks bateram com o pipeline local linha a linha (4.734.997 instalações, 54.609,1 MW).

4. Pipeline implementado

```
uv sync                          # Python 3.12 + dependências
cd pipeline
uv run python bronze.py          # baixa as 8 fontes (cerca de 1 minuto)
uv run python silver.py          # limpeza e integração
uv run python gold.py            # indicadores
uv run python analise.py         # correlações, modelo e clusters
uv run python graficos.py        # figuras em docs/img
uv run python dashboard.py       # docs/dashboard.html
```

Arquivo	Etapa	O que faz
`config.py`	configuração	URLs, caminhos e parâmetros
`bronze.py`	Bronze	download, conversão para Parquet, linhagem, manifesto
`silver.py`	Silver	filtro solar, tipagem, padronização, deduplicação, integração IBGE + INPE + tarifas
`gold.py`	Gold	corte do período estável, indicadores por município, mês e UF
`analise.py`	analytics	correlações, modelo de lacuna de adoção, clusters
`graficos.py` / `dashboard.py`	visualização	figuras estáticas e dashboard interativo

Resultado da Silver (`data/silver/_qualidade.json`):

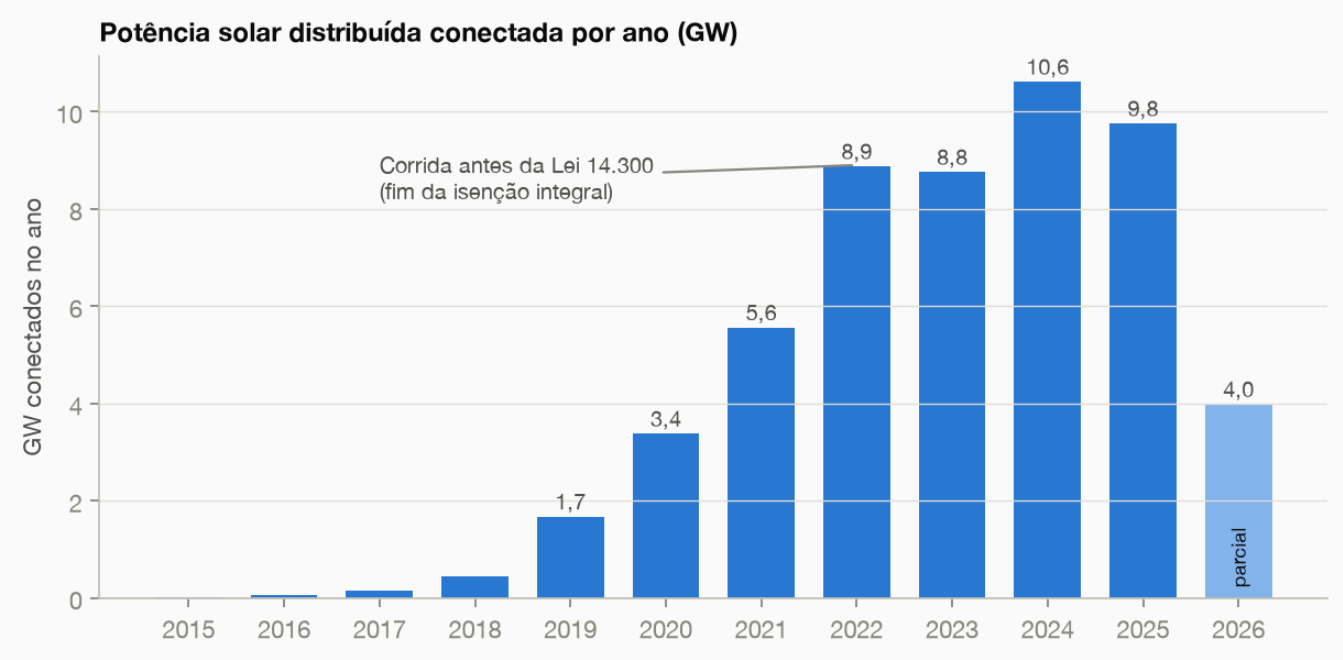
Checagem	Resultado
Registros na Bronze	4.735.908
Não solares removidos (térmicas, eólicas, hídricas)	905
Potência inválida ou duplicados	6
Instalações solares na Silver	4.734.997
Instalações sem município no IBGE	0
Municípios com irradiação: exato / exceção manual / aproximado / sem dado	5.552 / 7 / 10 / 2 (Fernando de Noronha e Boa Esperança do Norte, criado em 2025)
Municípios sem tarifa (sem nenhum sistema solar)	4

5. Feature Engineering

Feature	Construção	Por que importa
`watts_por_habitante`	potência total × 1000 / população	Adoção comparável entre municípios de tamanhos diferentes
`telhados_solares_por_mil_dom`	sistemas residenciais com geração na própria unidade / domicílios × 1000	Penetração real em residências, sem contar fazendas solares de autoconsumo remoto que inflam municípios pequenos
`pib_per_capita`	PIB 2023 / população 2022	Proxy de renda e capacidade de investimento
`irradiacao_kwh_m2_dia`	irradiação no plano inclinado / 1000	Potencial físico de geração
`geracao_kwh_por_kwp_ano`	irradiação × 365 × 0,75 (performance ratio típico)	Quanto 1 kWp gera por ano no município
`economia_r_por_kwp_ano`	geração por kWp × tarifa B1 da distribuidora	Retorno financeiro do painel, unindo sol e preço da energia
`tarifa_b1_r_kwh`	(TUSD + TE) da tarifa residencial convencional vigente da distribuidora principal	Quanto a energia pesa no bolso
`pct_apartamentos`	% de domicílios do tipo apartamento	Barreira física ao telhado próprio
`pct_kw_autoconsumo_remoto`, `pct_kw_rural`	participação na potência	Diferencia adoção doméstica de investimento e agronegócio
`kw_ultimos_12m`, `crescimento_12m_pct`	potência conectada nos 12 meses do período estável e variação contra os 12 anteriores	Momento do mercado, sem o viés do atraso de registro
`telhados_esperados_por_mil_dom`, `razao_adocao`, `telhados_faltantes`	previsão do modelo (seção 7) e diferença para o observado	Mede quanto o município está abaixo do que seu perfil permitiria
`economia_nao_capturada_r_ano`	telhados faltantes × 5 kWp (mediana residencial) × economia por kWp	Traduz a lacuna em reais por ano

6. Camada analítica e indicadores

Indicador	Definição	Dados	Resultado	Interpretação para decisão
Potência instalada	soma da potência dos sistemas solares	ANEEL	**54,6 GW**, 4,73 milhões de sistemas	Dimensão do mercado
W por habitante	potência / população	ANEEL + IBGE	Brasil 269. MT 872, MS 699, PR 600. AM 115, RJ 130, SE 147	Onde a adoção está concentrada
Telhados por mil domicílios	sistemas residenciais próprios / domicílios	ANEEL + IBGE	Centro-Oeste 70, Sul 47, Sudeste 33, **Nordeste 30**	Acesso das famílias à geração própria
Participação Nordeste	% da potência vs % da população	ANEEL + IBGE	**20,6% da potência para 26,9% da população**	Sub-representação da região com mais sol
Economia por kWp/ano	geração × tarifa	INPE + ANEEL	Centro-Oeste R$ 1.353, Norte R$ 1.226, **Nordeste R$ 1.216**, Sul R$ 1.039	Um painel no Nordeste rende 17% mais que no Sul
Concentração	% da potência nos 10% maiores municípios	ANEEL	58,8%	Mercado muito concentrado
Autoconsumo remoto	% da potência em fazendas solares remotas	ANEEL	29,1%	Parte relevante é investimento, não telhado
Crescimento em 12 meses	jun/25 a mai/26 contra jun/24 a mai/25	ANEEL	Brasil -2,3%, **Nordeste +12,4%** (única região em alta)	O Nordeste começou a reagir, momento certo para política pública



A curva mostra a corrida de 2022 antes da Lei 14.300 (que acabou com a isenção integral da tarifa de uso da rede para novos sistemas a partir de 2023), a queda em 2023 e a recuperação em 2024. 2026 está incompleto por causa do atraso de registro.

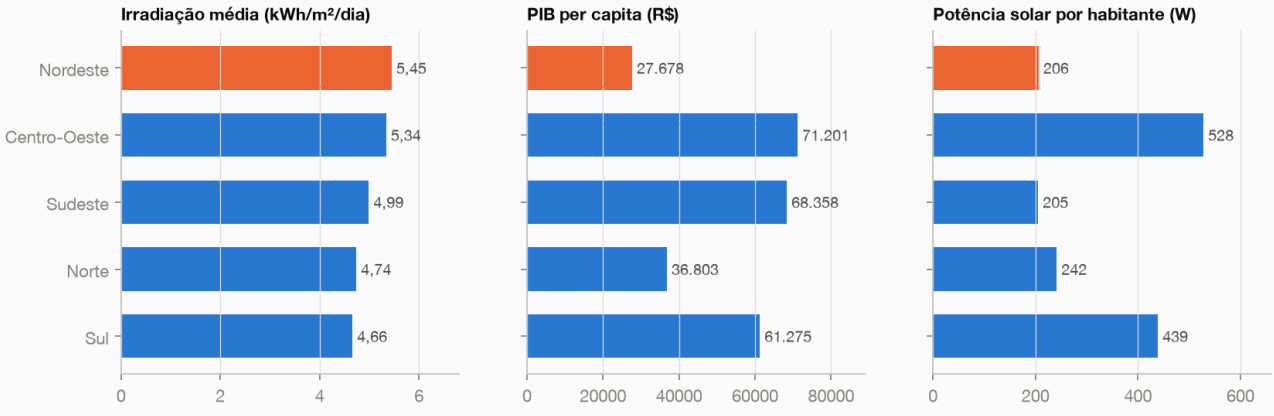
Onde há sol
irradiação no plano inclinado (kWh/m²/dia)

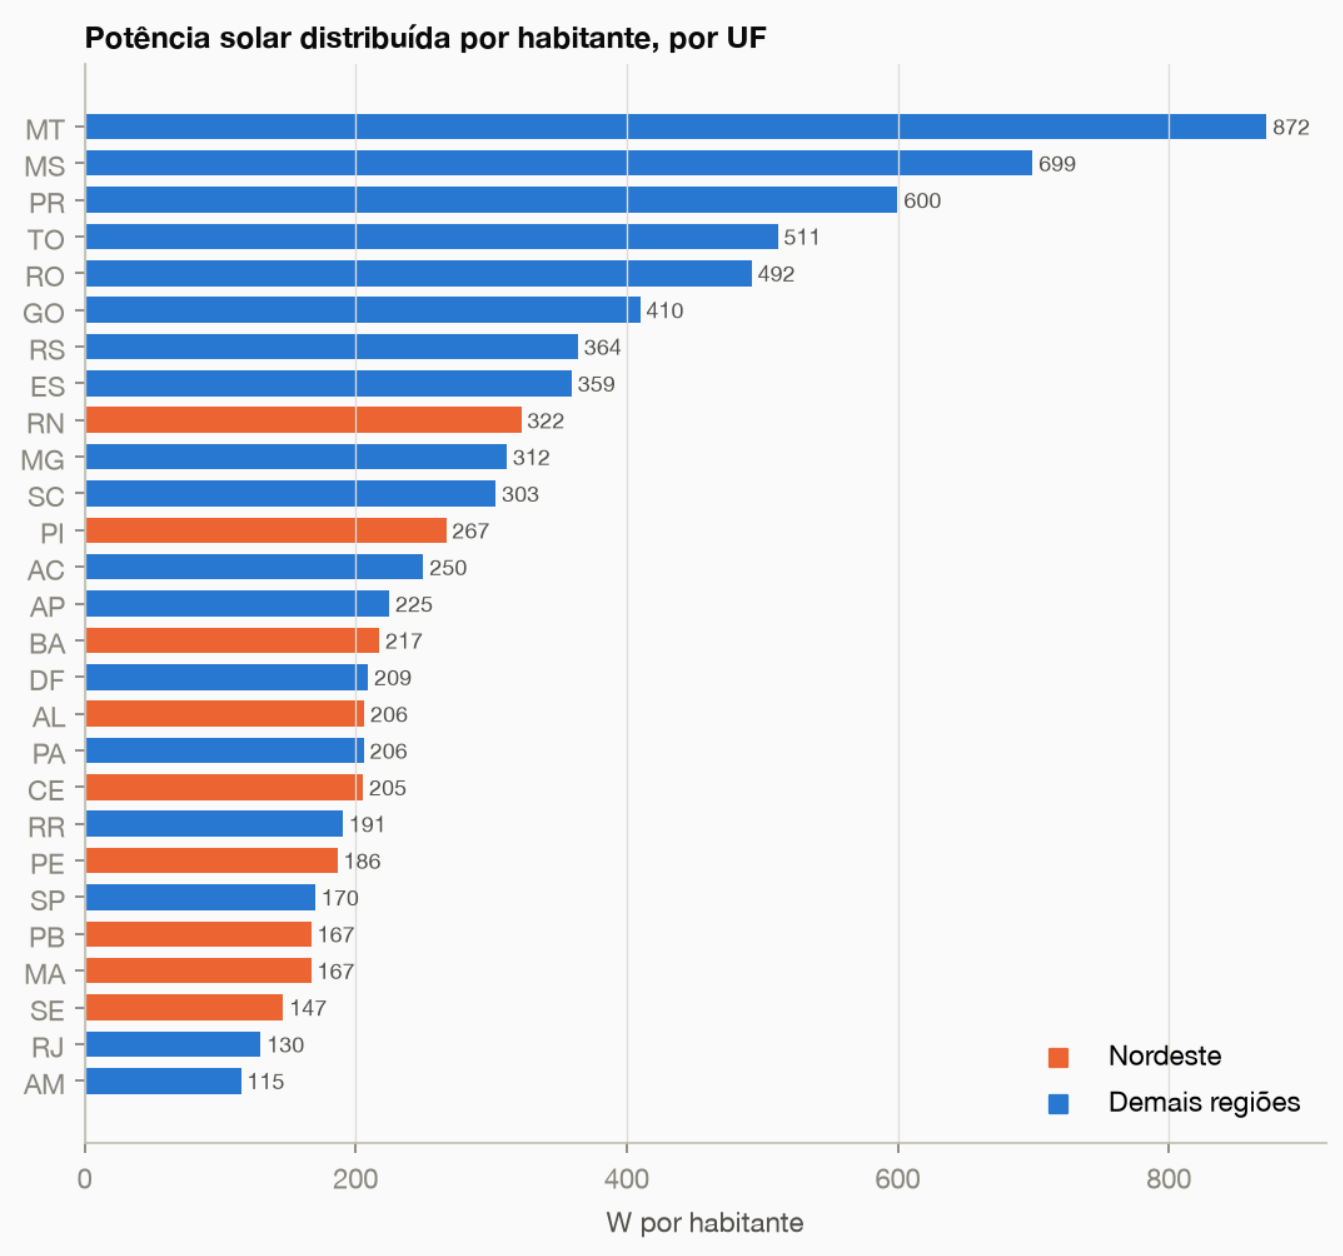


Onde há painéis
potência instalada por habitante (W/hab, escala log)



Nordeste: mais sol do país, menor renda e menor adoção por habitante



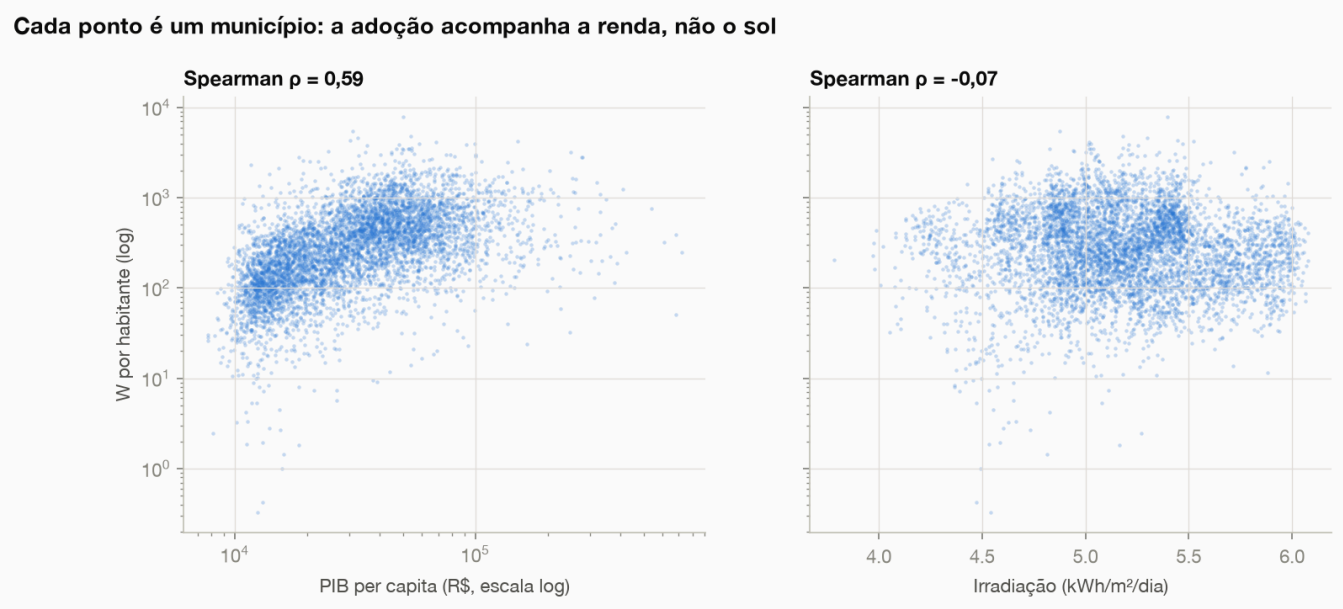


7. Análises avançadas

7.1 Correlação: renda explica, sol não

Correlação de Spearman entre fatores e adoção nos 5.565 municípios com dados completos. Spearman foi escolhido porque as variáveis são muito assimétricas (W/hab vai de 0 a 7.939) e a relação esperada é monotônica, não necessariamente linear.

Fator	W por habitante	Telhados por mil domicílios
PIB per capita	**0,59**	**0,52**
% rural da potência	0,38	0,16
Tarifa residencial	0,07	0,15
% de apartamentos	0,14	0,15
Irradiação solar	**-0,07**	-0,02 (não significativo)
População	-0,17	-0,03 (não significativo)



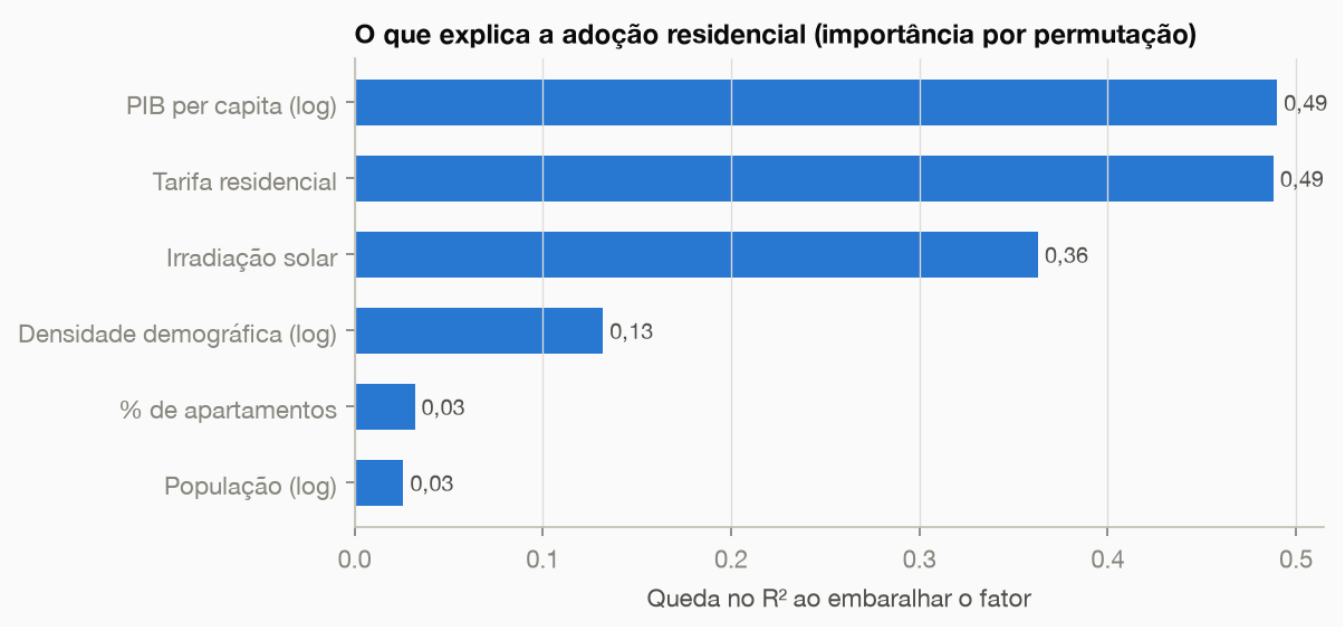
7.2 Modelo de adoção esperada (Machine Learning)

Objetivo. Estimar quantos telhados solares por mil domicílios cada município "deveria" ter, dado o seu perfil, e encontrar os que estão abaixo disso. Não é um modelo para prever o futuro, e sim um padrão de comparação justo: comparar Salvador com municípios de renda, sol, tarifa e verticalização parecidos, e não com Cuiabá.

Método. Regressão com Gradient Boosting (`HistGradientBoostingRegressor`) sobre `log(1 + telhados por mil domicílios)`, com 6 fatores estruturais: PIB per capita (log), irradiação, tarifa, % de apartamentos, população (log) e densidade (log). A previsão de cada município é feita **fora da amostra** (validação cruzada com 5 folds), então nenhum município é usado para prever a si mesmo.

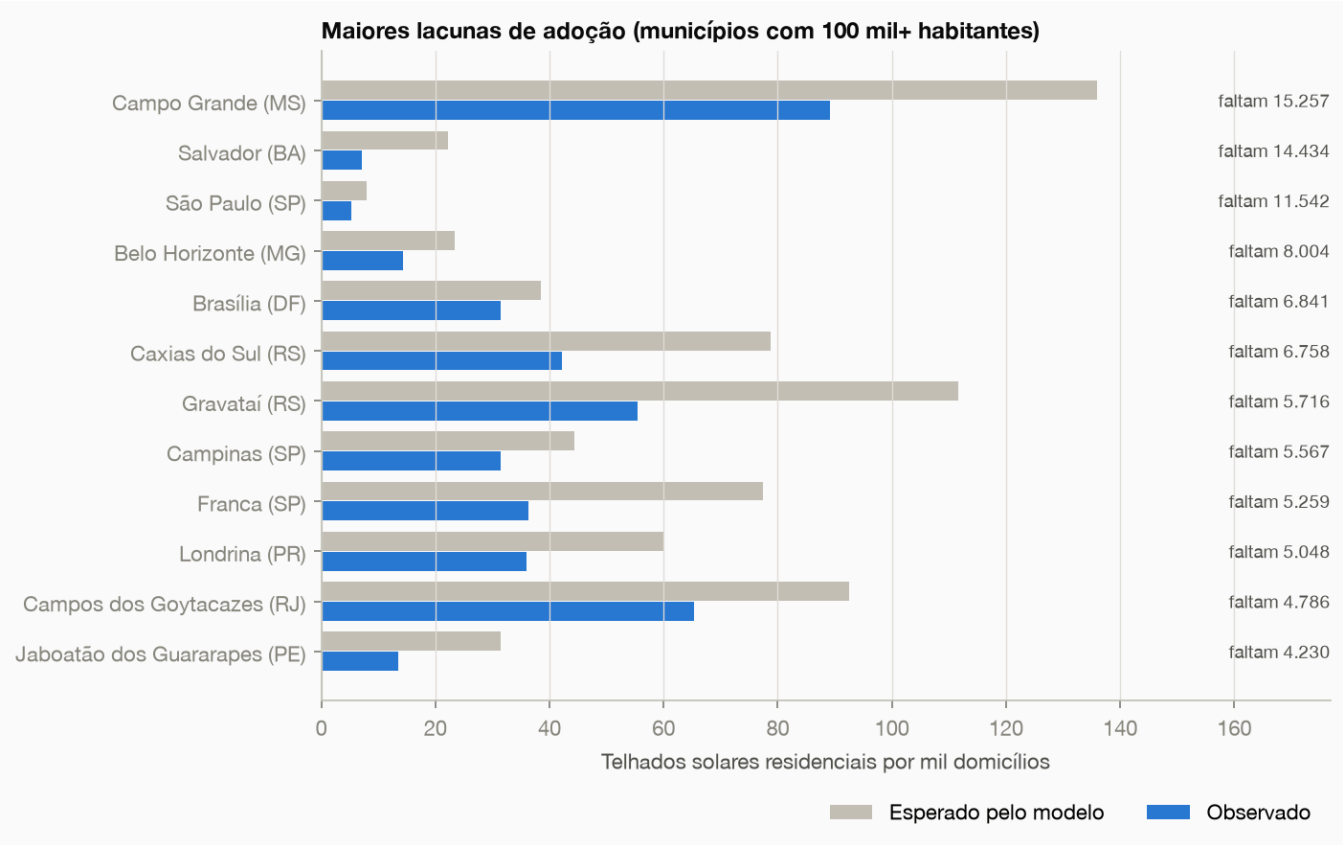
Modelo	R² (KFold)	MAE (telhados/mil dom.)	R² (validação por UF)
Baseline (média)	0,00	27,2	-0,03
Regressão linear	0,28	24,5	0,23
Gradient Boosting	**0,62**	**16,8**	-0,02

Leitura das métricas. O Gradient Boosting explica 62% da variação e reduz o erro em 38% em relação ao baseline. Porém, quando um estado inteiro fica de fora do treino (validação por UF), o desempenho cai a zero: o modelo aprende padrões regionais (distribuidora, mercado local, histórico de incentivos estaduais) que não se transferem para um estado que ele nunca viu. Por isso ele é usado apenas para comparar municípios dentro do contexto conhecido, que é o uso pretendido, e não para estimar estados novos.



Importância por permutação (queda do R^2 ao embaralhar cada fator): renda (0,49) e tarifa (0,49) dominam. A irradiação aparece (0,36) porque, combinada com os outros fatores, ajuda a separar regiões, embora sozinha não tenha correlação com a adoção.

Resultado. Somando a diferença entre esperado e observado, há **373 mil telhados residenciais abaixo do esperado** no país, o equivalente a **R$ 2,25 bilhões por ano** de economia na conta de luz que as famílias deixam de capturar.



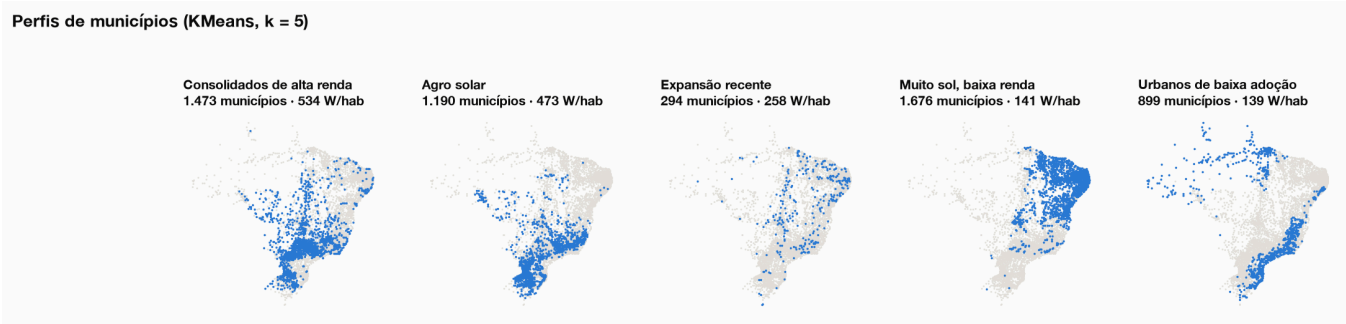
Salvador (28% de apartamentos) tem 7 telhados solares por mil domicílios, quando o esperado seria 22. Jaboatão dos Guararapes, Caucaia e Recife aparecem na mesma situação. São cidades do Nordeste com sol forte e tarifa média, onde a barreira é renda e moradia.

Limitações. O PIB per capita é uma proxy imperfeita de renda das famílias (o Censo 2022 ainda não publicou renda domiciliar por município em todas as tabelas). O modelo não vê crédito disponível, informalidade da moradia nem ICMS estadual. A lacuna é uma estimativa para priorização, não uma meta exata.

7.3 Perfis de municípios (clusterização)

KMeans sobre 6 variáveis padronizadas (W/hab em log, PIB per capita em log, irradiação, % rural, % autoconsumo remoto, % da potência conectada nos últimos 12 meses), em 5.532 municípios com pelo menos 10 sistemas. O número de grupos (k = 5) foi escolhido pela maior silhueta entre k = 3 e 7.

Perfil	Municípios	População	W/hab (mediana)	PIB per capita	Irradiação	Destaque
Consolidados de alta renda	1.473	63,7 mi	534	R$ 50 mil	5,22	Interior do Sul, Sudeste e Centro-Oeste
Agro solar	1.190	10,1 mi	473	R$ 41 mil	4,95	44% da potência em propriedades rurais
Expansão recente	294	4,8 mi	258	R$ 22 mil	5,31	55% da potência conectada nos últimos 12 meses
Muito sol, baixa renda	**1.676**	**48,4 mi**	**141**	**R$ 15 mil**	**5,48**	88% no Nordeste. Metade da potência é autoconsumo remoto (investidores de fora)
Urbanos de baixa adoção	899	75,6 mi	139	R$ 27 mil	4,80	Regiões metropolitanas e litoral do Sudeste e Norte



Limitações. A silhueta de 0,20 indica grupos com sobreposição. Os perfis servem para orientar o tipo de política, não como categorias rígidas.

8. Dashboard

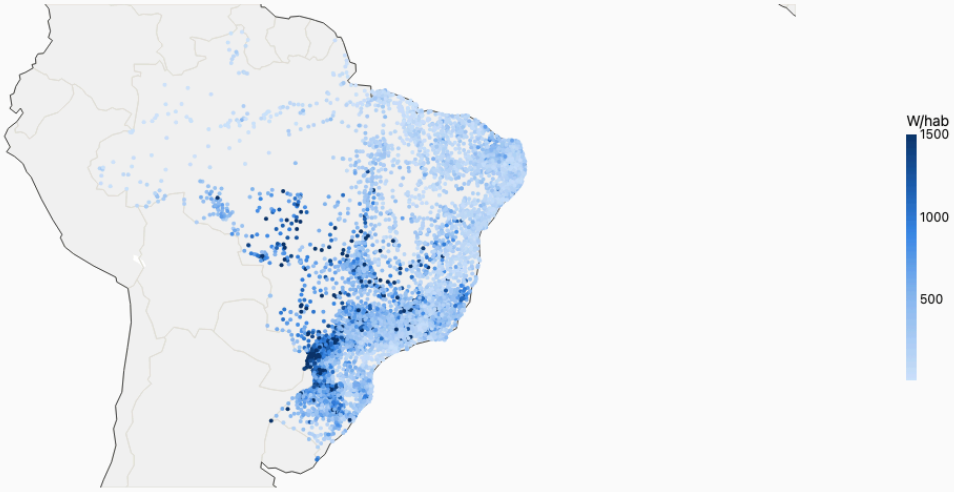
`docs/dashboard.html` é um painel interativo (Plotly) que abre em qualquer navegador: indicadores principais, mapa de W/hab por município com detalhes ao passar o mouse, evolução mensal por região, comparação entre UFs e a tabela de lacunas.

Energia solar distribuída no Brasil: onde o sol não vira painel

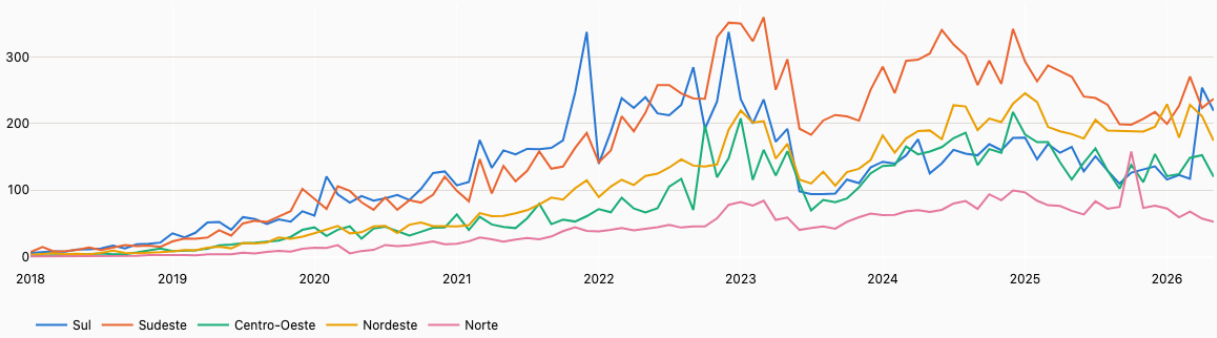
Fontes: ANEEL (geração distribuída e tarifas), INPE/LABREN (Atlas Solar), IBGE (Censo 2022 e PIB 2023). Série mensal até 05/2026.

4.734.963	54,6 GW	269	373.313	R$ 2,25 bi
sistemas solares conectados	potência instalada	W por habitante (Brasil)	telhados residenciais abaixo do esperado	economia anual não capturada

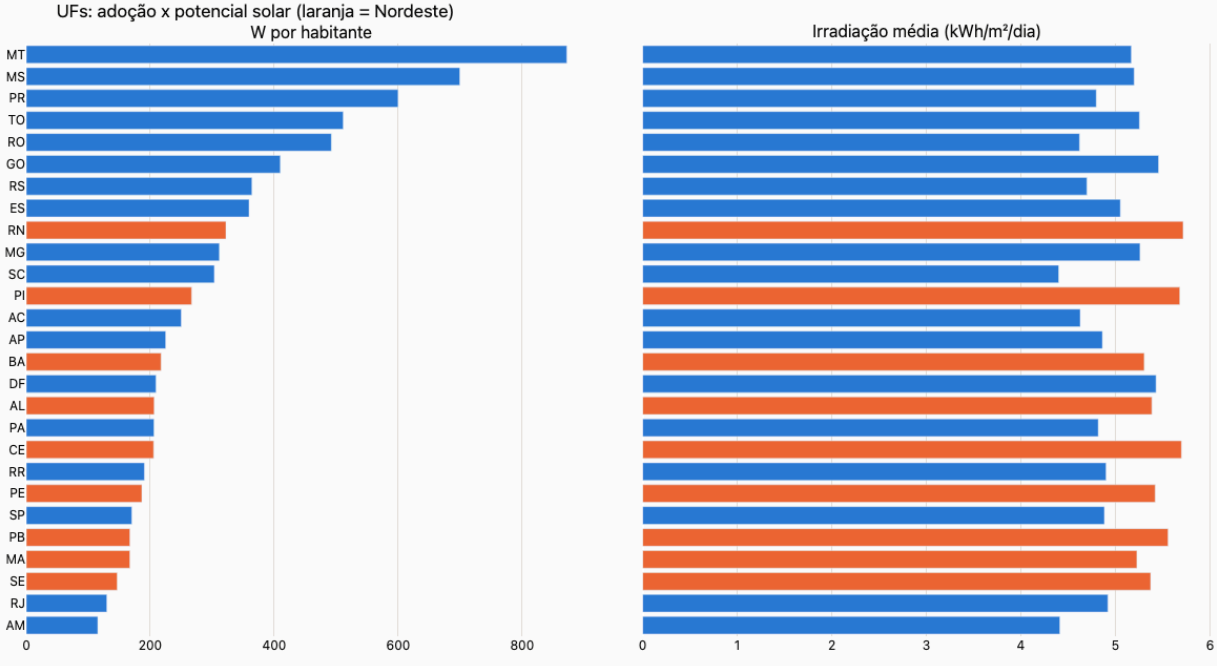
Potência solar por habitante, por município



Potência conectada por mês e região (MW)



UFs: adoção x potencial solar (laranja = Nordeste)



Maiores lacunas de adoção residencial (municípios com 100 mil+ habitantes)

Município	Telhados/mil dom.	Esperado	Telhados faltantes	Economia não capturada/ano
Campo Grande (MS)	89,2	136,0	15.257	R$ 107,9 mi
Salvador (BA)	7,2	22,2	14.434	R$ 93,6 mi
São Paulo (SP)	5,3	8,0	11.542	R$ 58,3 mi
Belo Horizonte (MG)	14,3	23,3	8.004	R$ 52,9 mi
Brasília (DF)	31,5	38,4	6.841	R$ 42,4 mi
Caxias do Sul (RS)	42,1	78,7	6.758	R$ 40,2 mi
Gravataí (RS)	55,5	111,6	5.716	R$ 34,1 mi
Campinas (SP)	31,4	44,4	5.567	R$ 29,1 mi
Franca (SP)	36,3	77,4	5.259	R$ 28,4 mi
Londrina (PR)	35,9	60,0	5.048	R$ 27,3 mi
Campos dos Goytacazes (RJ)	65,3	92,6	4.786	R$ 35,5 mi
Jaboatão dos Guararapes (PE)	13,4	31,4	4.230	R$ 25,2 mi
Caucaia (CE)	28,7	57,3	3.450	R$ 18,9 mi
Betim (MG)	22,5	42,1	2.881	R$ 19,2 mi
Joinville (SC)	42,6	55,5	2.868	R$ 11,9 mi

Esperado: previsão fora da amostra de um modelo Gradient Boosting com renda, irradiação, tarifa, % de apartamentos, porte e densidade. Economia não capturada: telhados faltantes × 5 kWp (mediana residencial) × economia anual por kWp do município.

9. Experimentação com Databricks e Apache Spark

O notebook `databricks/pipeline_energia_solar.py` reimplementa o pipeline inteiro (Bronze, Silver e Gold) em PySpark com tabelas Delta no Databricks Free Edition.

Como executar. Workspace > Import > arquivo `databricks/pipeline_energia_solar.py` > Run all. O notebook cria o schema `workspace.energia_solar` e o volume `raw`, baixa as 8 fontes direto das URLs públicas e grava 13 tabelas Delta.

O que foi investigado	Como foi feito no notebook
Carregar datasets	`spark.read.parquet` (ANEEL), `spark.read.csv` com separador `;` (INPE), `spark.read.json` com `multiLine` (IBGE)
Transformações em DataFrames	`select`, `cast`, `trim`, `create_map` para padronizar categorias, `when` para datas sentinela, `try_cast` para valores `–` e `...` da SIDRA
Integração de fontes	`join` pelo código IBGE, `pivot` das tabelas SIDRA, `left_anti` para achar quem ficou sem correspondência e `levenshtein` para a junção aproximada de nomes do INPE
Agregações e consultas	`groupBy().agg()`, `Window` + `row_number` para deduplicação e tarifa vigente, Spark SQL com `FILTER (WHERE ...)`, `GROUP BY ALL` e funções de janela
Armazenar e consultar	`saveAsTable` e `CREATE OR REPLACE TABLE` em Delta Lake no Unity Catalog, consultas `%sql`
Processamento distribuído	plano físico com `explain(mode="formatted")`

Evidência da execução. O notebook foi exportado do Databricks **com as saídas** depois de executado:

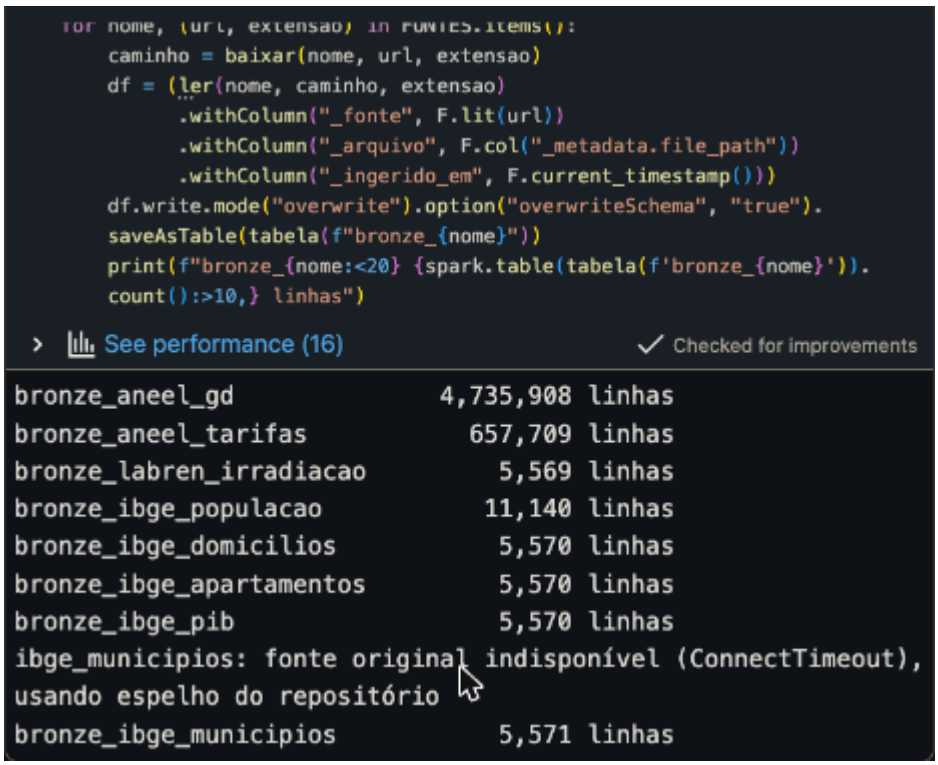
- `databricks/pipeline_energia_solar_executado.ipynb`: abre direto no GitHub, com a data, a hora e a duração de cada célula e todas as saídas (contagens, tabelas e plano físico).
- `databricks/pipeline_energia_solar_executado.html`: exportação HTML original do Databricks. Para ver, baixe o arquivo e abra no navegador.

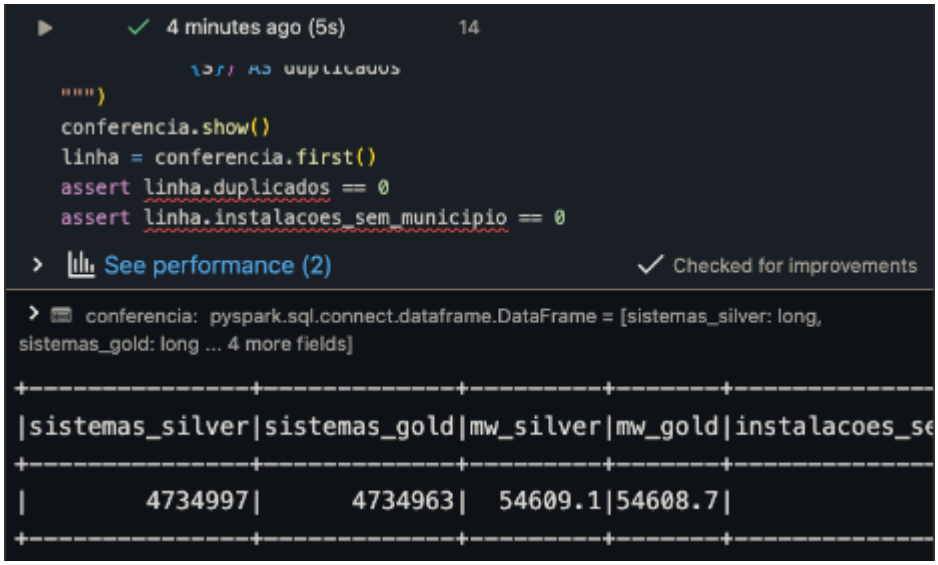
O caminho interno do armazenamento gerenciado (S3 do Unity Catalog), que aparece no plano físico, foi mascarado nos dois arquivos.

Resultado da execução no Databricks Free Edition (compute serverless com Photon, 09/11/2026):

Etapa	Resultado no Databricks	Pipeline local
Bronze	8 tabelas Delta, `bronze_aneel_gd` com 4.735.908 linhas	4.735.908
Silver	`silver_instalacoes_solares` com 4.734.997 linhas, 54.609,1 MW	4.734.997, 54.609,1 MW
Integração INPE	5.552 exatos, 7 por exceção, 10 aproximados (Levenshtein)	5.552 / 7 / 10 (difflib)
Gold	`gold_municipios` 5.570 linhas, `gold_ufs` 27 linhas, período estável até maio/2026	igual
Qualidade	0 duplicados, 0 instalações sem município (`assert`)	igual

A API de Localidades do IBGE (`servicodados.ibge.gov.br`) não respondeu a conexões vindas da nuvem do Databricks (timeout), enquanto a API SIDRA do mesmo IBGE funcionou. O notebook trata isso usando uma cópia idêntica do arquivo versionada em `databricks/espelho/`, e registra no log quando o espelho é usado.





4 minutes ago (3s) 16

```sql
%sql
SELECT regiao,
       round(sum(potencia_kw) * 1000 / sum(populacao)) AS
       watts_por_habitante,
       round(sum(irradiacao_kwh_m2_dia * populacao) / sum(populacao),
       2) AS irradiacao_media,
       round(sum(pib_per_capita * populacao) / sum(populacao)) AS
       pib_per_capita,
       round(100 * sum(potencia_kw) / sum(sum(potencia_kw)) OVER (),
       1) AS pct_potencia_brasil,
       round(100 * sum(populacao) / sum(sum(populacao)) OVER (), 1) AS
       pct_populacao_brasil
FROM workspace.energia_solar.gold_municipios
GROUP BY regiao
ORDER BY watts_por_habitante DESC
```

See performance (1) Checked for improvements

Table

	regiao	1.2 watts_por_habitante	1.2 irradiacao_media	1.2 pib_per
1	Centro-Oe...	528	5.34	
2	Sul	439	4.66	
3	Norte	240	4.74	
4	Nordeste	206	5.45	
5	Sudeste	205	4.99	

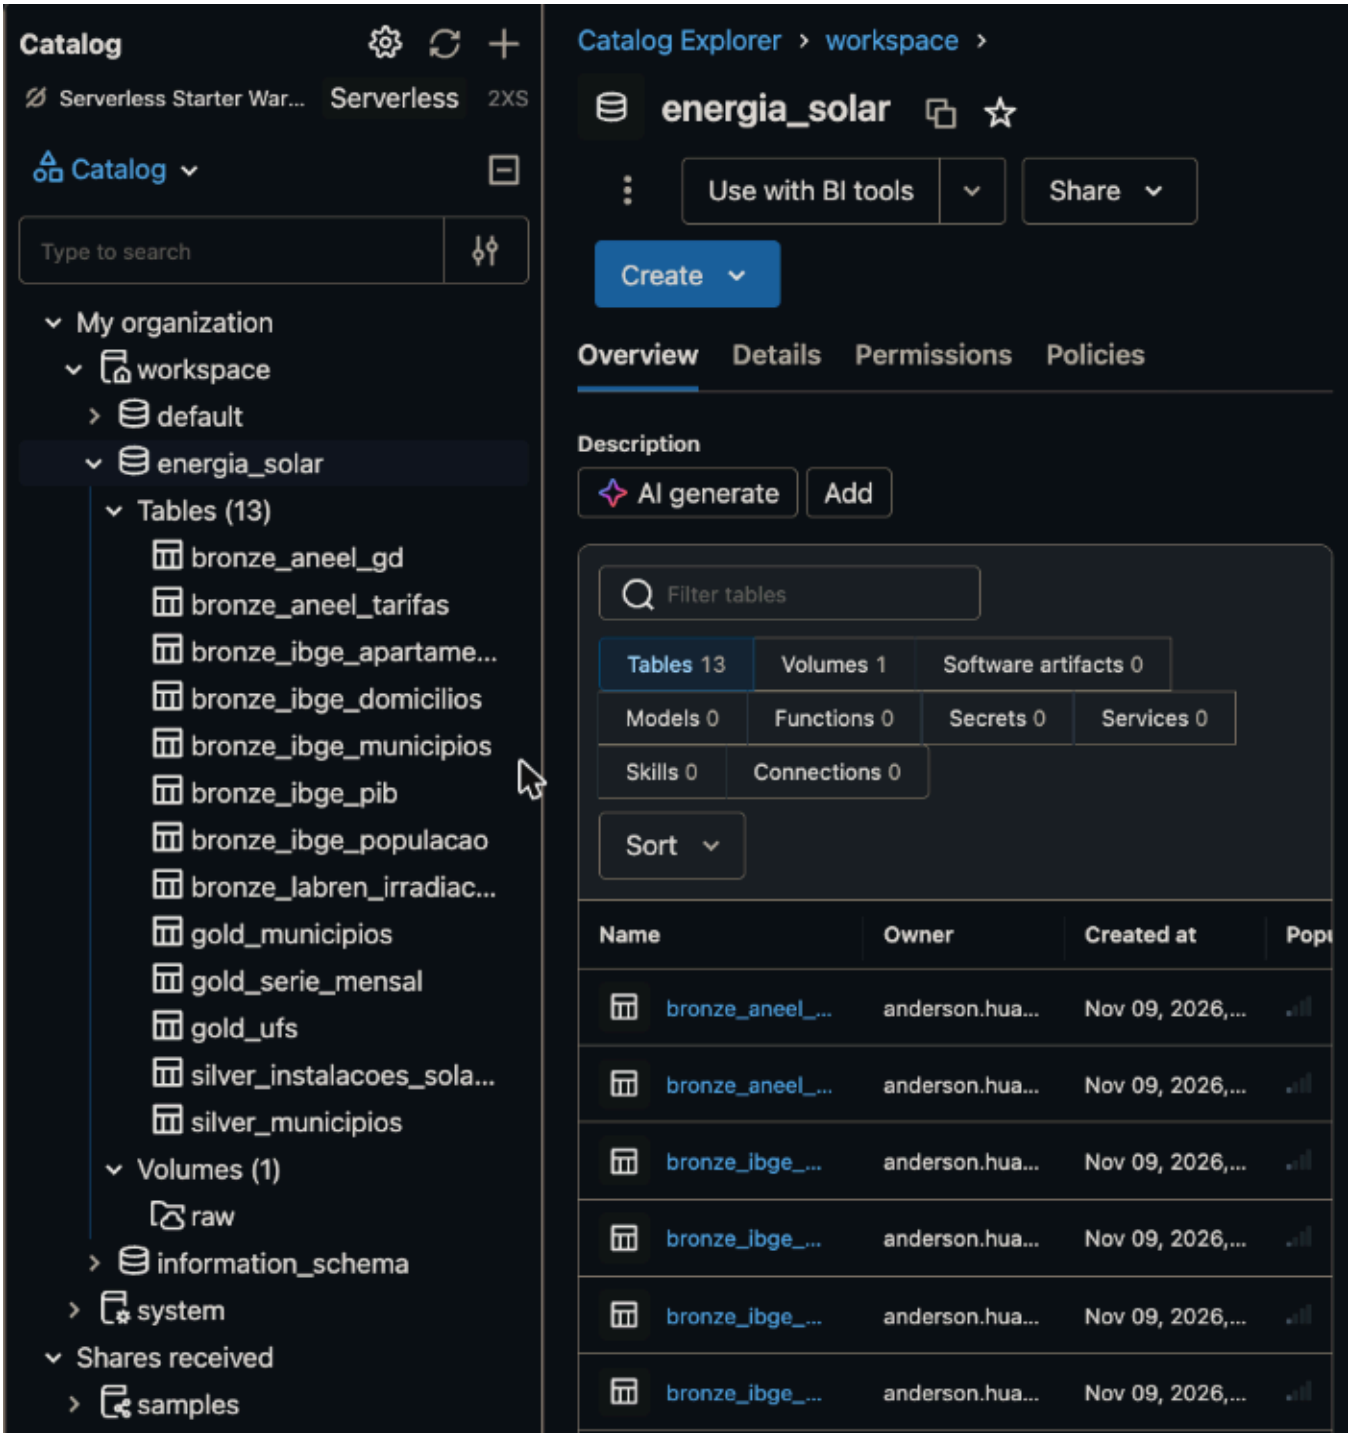
5 rows 3.292s runtime Refreshed at 11/9/26, 6:10 PM (4m ago)

4 minutes ago (1s) 20

```python
(spark.table(tabela("bronze_aneel_gd"))
    .filter(F.col("SigTipoGeracao") == "UFV")
    .groupBy("CodMunicipioIbge")
    .agg(F.sum("MdaPotenciaInstaladaKW").alias("kw"))
    .explain(mode="formatted"))
```

```
== Physical Plan ==
AdaptiveSparkPlan (6)
+- == Initial Plan ==
   PhotonResultStage (5)
   +- PhotonColumnarToRow (4)
      +- PhotonGroupingAgg (3)
         +- PhotonProject (2)
            +- PhotonScan parquet workspace.energia_solar.bron
ze_aneel_gd (1)


(1) PhotonScan parquet workspace.energia_solar.bronze_aneel_gd
Output [3]: [CodMunicipioIbge#34368L, SigTipoGeracao#34376, Md
aPotenciaInstaladaKW#34379]
DictionaryFilters: [(SigTipoGeracao#34376 = UFV)]
Location: PreparedDeltaFileIndex [s3://dbstorage-prod-h8tj0aga
```



Discussão.

- **Características:** a mesma lógica foi escrita de forma declarativa e o otimizador do Spark decidiu a execução. No Databricks, o plano físico mostra o motor vetorizado Photon (`PhotonScan`, `PhotonGroupingAgg`), o filtro `SigTipoGeracao = 'UFV'` aplicado já na leitura da tabela Delta (`DictionaryFilters`) e a leitura de apenas 3 das 29 colunas (column pruning). No Spark local, o mesmo código gera a agregação em duas fases: soma parcial em cada partição (`partial_sum`), troca de dados por município (`Exchange hashpartitioning`) e soma final. Esse padrão é o que permite dividir o trabalho entre várias máquinas.
- **Possibilidades:** com a base histórica mensal da ANEEL (uma foto por mês desde 2018, centenas de milhões de linhas) ou com dados de medição horária das distribuidoras, o volume deixa de caber em uma máquina. O mesmo código roda em um cluster maior sem alterações. As tabelas Delta ficam disponíveis para SQL e dashboards sem exportar arquivos.

- **Limitações:** para 4,7 milhões de linhas, o DuckDB local é mais rápido de iterar (segundos, sem tempo de inicialização de cluster). A Free Edition tem cotas de computação, o modo ANSI do SQL exige `try_cast` e `nullif` para não quebrar com dados sujos, e a junção aproximada de nomes, trivial em Python com `difflib`, precisou ser reescrita com `levenshtein` e janela.

10. Relatório executivo

Diagnóstico e recomendações em `relatorio-executivo.md`.

11. Indo além do enunciado: governança e linhagem de dados

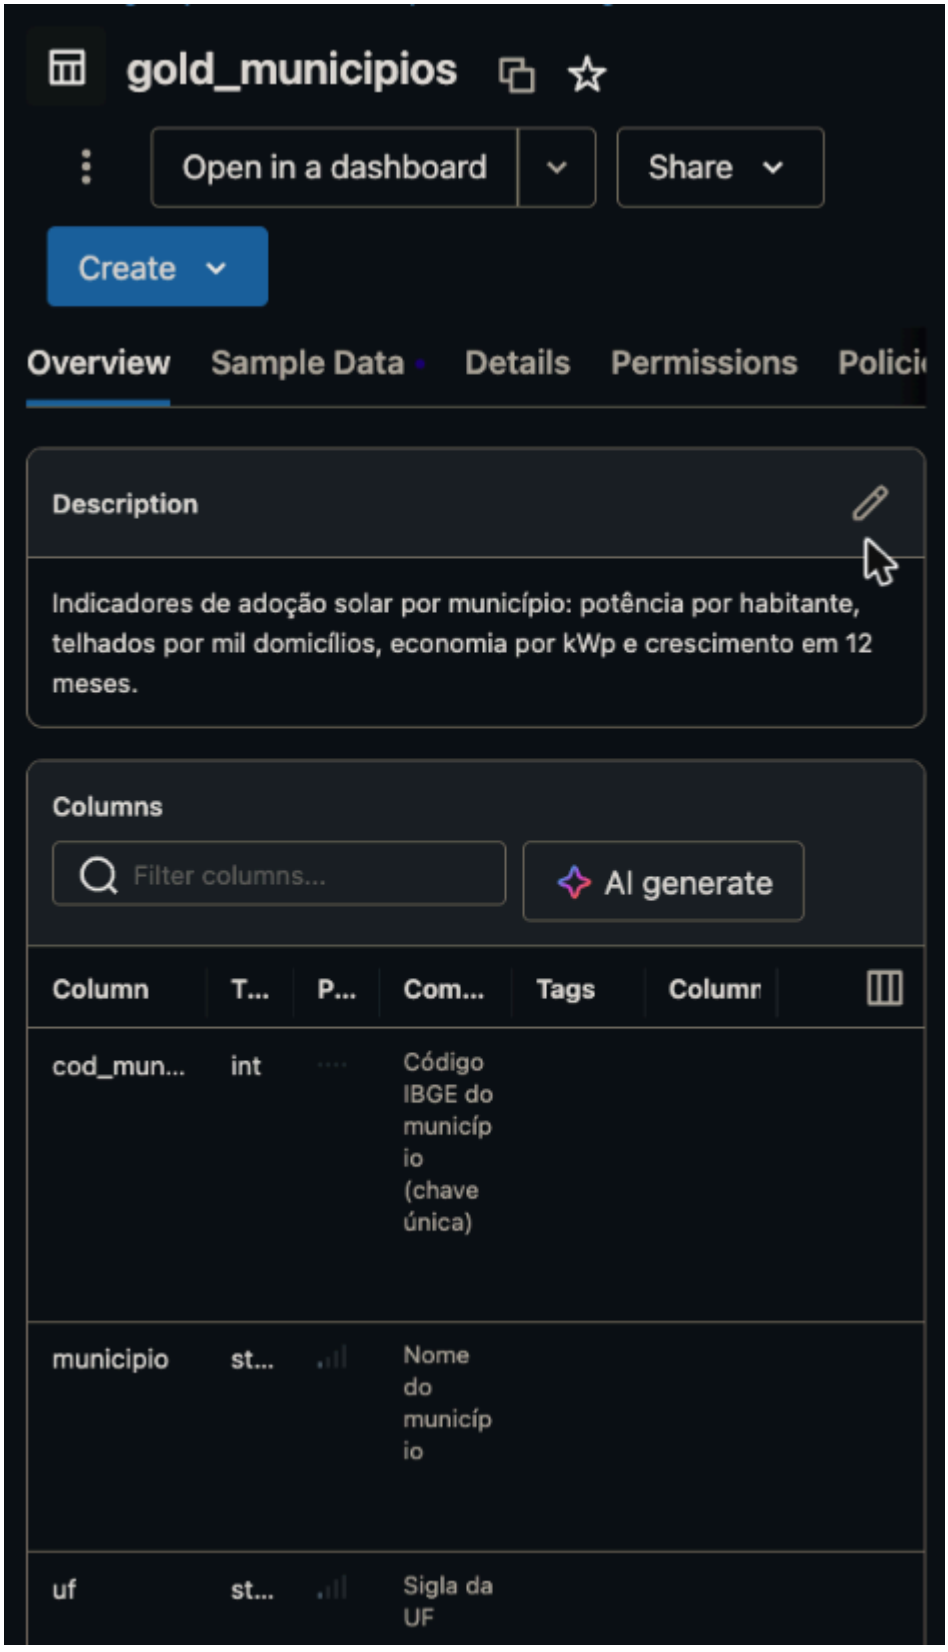
> Esta seção é uma **contribuição adicional**, feita além do escopo pedido na atividade. Ela não altera nenhum dado, código ou resultado das seções anteriores: apenas documenta, no próprio banco, as tabelas que o pipeline já havia criado.

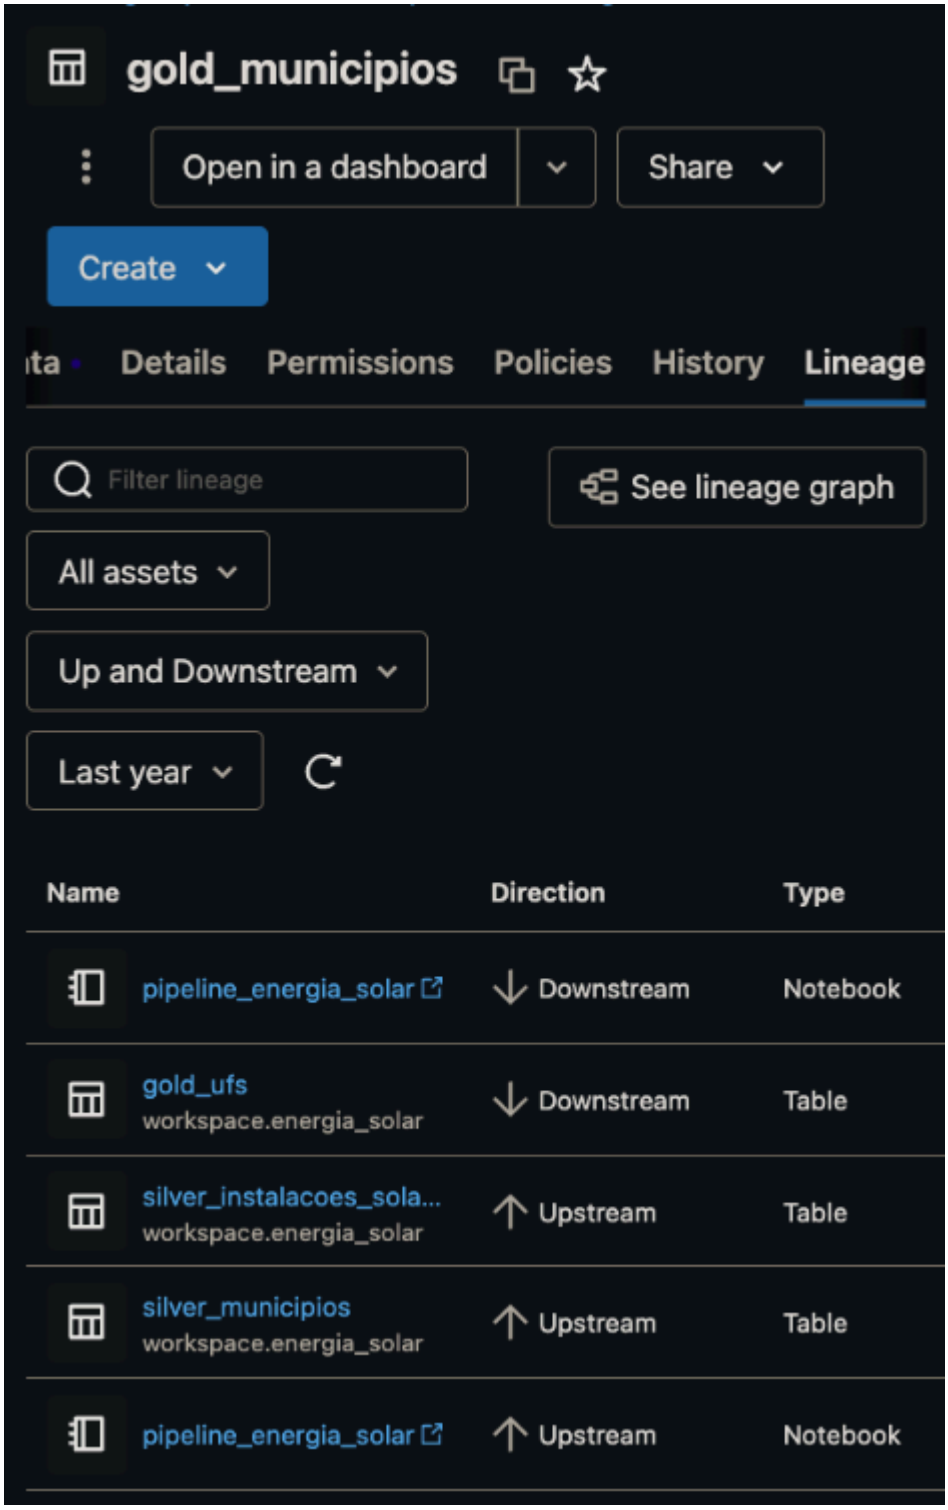
Por que isso importa em um banco de dados na nuvem. Em um ambiente compartilhado, com dezenas de tabelas e várias pessoas consultando, não basta os dados existirem: é preciso saber **o que cada tabela e coluna significa**, **de onde ela veio** e **se contém dados pessoais**. Sem isso, o data lake vira um "pântano de dados" em que ninguém confia. O Unity Catalog do Databricks resolve isso guardando esses metadados junto com as tabelas.

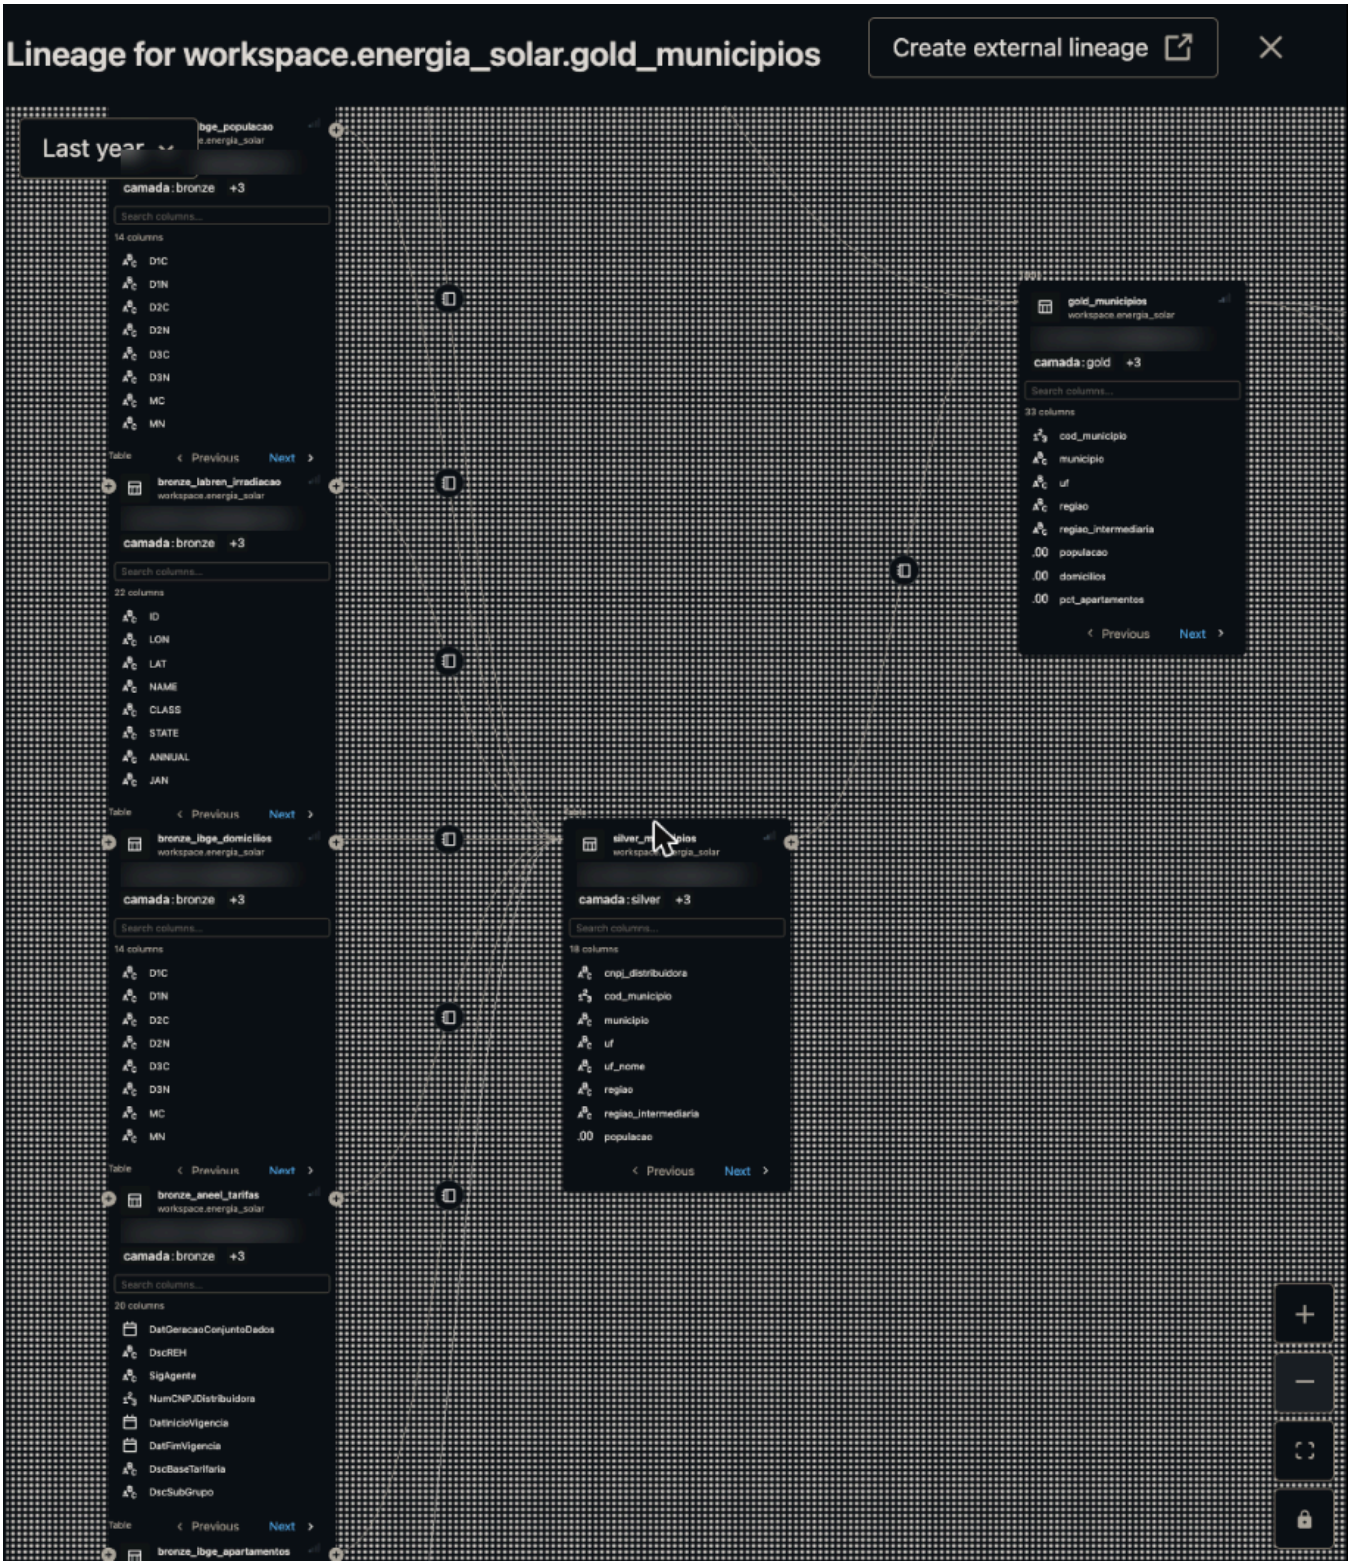
O que foi feito (notebook separado, `databricks/extra_catalogo_linhagem.py`):

Recurso	Como	Resultado
Descrição das tabelas	`COMMENT ON TABLE`	As 13 tabelas descritas, aparecendo na interface e no `information_schema`
Dicionário de dados no banco	`ALTER TABLE ... ALTER COLUMN ... COMMENT`	59 colunas da Silver e da Gold documentadas, com unidade e fonte
Classificação por tags	`ALTER TABLE ... SET TAGS`	Cada tabela com `camada` (bronze, silver, gold), `fonte` (ANEEL, IBGE, INPE), `lgpd = sem_dados_pessoais` e `projeto`
Catálogo consultável por SQL	`information_schema.tables`, `table_tags` e `columns`	Os metadados podem ser consultados como qualquer tabela
Linhagem de dados	registrada automaticamente pelo Unity Catalog	Grafo mostrando de quais tabelas Bronze vem cada Silver, de qual Silver vem cada Gold e qual notebook fez cada escrita

Evidências. O notebook foi executado no Databricks e exportado com as saídas: `extra_catalogo_linhagem_executado.ipynb` (abre no GitHub) e `extra_catalogo_linhagem_executado.html`.


gold_municipios
Open in a dashboard
Share
Create
Overview
Sample Data
Details
Permissions
Polici
Description
Indicadores de adoção solar por município: potência por habitante, telhados por mil domicílios, economia por kWp e crescimento em 12 meses.
Columns
Filter columns...
AI generate
Column
T...
P...
Com...
Tags
Columr
cod_mun...
int
Código IBGE do município (chave única)
municipio
st...
Nome do município
uf
st...
Sigla da UF


gold_municipios
Open in a dashboard
Share
Create
Details
Permissions
Policies
History
Lineage
Filter lineage
See lineage graph
All assets
Up and Downstream
Last year
Name
Direction
Type
pipeline_energia_solar
Downstream
Notebook
gold_ufs
workspace.energia_solar
Downstream
Table
silver_instalacoes_sola...
workspace.energia_solar
Upstream
Table
silver_municipios
workspace.energia_solar
Upstream
Table
pipeline_energia_solar
Upstream
Notebook



No grafo, cada caixa é uma tabela Delta com a sua tag `camada`: as tabelas Bronze do IBGE, do INPE e da ANEEL alimentam `silver_municipios`, que alimenta `gold_municipios`. O e-mail do dono das tabelas foi borrado no print.

Observações.

- A tabela de sistema `system.access.table_lineage` (consulta no fim do notebook) voltou vazia nesta execução: as tabelas de sistema do Databricks são atualizadas com algumas horas de atraso. A interface do catálogo, porém, já mostrava a linhagem completa, como nos prints acima.

- O notebook deve ser executado **depois** do pipeline principal, porque recriar as tabelas apaga os comentários e as tags.

Estrutura do repositório

```
pipeline/            código do pipeline local (Bronze, Silver, Gold, análises, gráficos,
dashboard)
databricks/          notebook PySpark do pipeline completo no Databricks e notebook extra de
governança
docs/                dashboard, diagrama de arquitetura, figuras e resultados.json
data/                camadas raw, bronze, silver e gold (geradas pelo pipeline, fora do Git)
relatorio-executivo.md
```

Relatório executivo: onde o sol não vira painel

Para: gestores de política energética e de habitação (MME, ANEEL, governos estaduais, bancos públicos de fomento) **Autor:** Anderson Huang, RM 565920 · CitizenTech · Global Solution 2026.2 **Base:** 4,73 milhões de sistemas solares (ANEEL, novembro/2026), Atlas Solar (INPE), tarifas (ANEEL), Censo 2022 e PIB 2023 (IBGE)

Resumo

O Brasil tem 54,6 GW de energia solar distribuída, mas ela está onde há renda, não onde há sol. O Nordeste recebe a maior irradiação do país e cada painel instalado lá economiza 17% a mais por ano do que no Sul. Mesmo assim, a região tem 26,9% da população e só 20,6% da potência instalada, com 30 telhados solares por mil domicílios contra 70 no Centro-Oeste. A renda (PIB per capita) tem correlação de 0,59 com a adoção. A irradiação tem correlação nula (-0,07). Nossa estimativa é de 373 mil telhados residenciais abaixo do esperado no país, o equivalente a R$ 2,25 bilhões por ano de economia que as famílias deixam de ter na conta de luz.

1. O que os dados revelam

- **A adoção segue a renda.** Entre os 5.565 municípios analisados, os mais ricos têm muito mais painéis por habitante, independentemente do sol. O sol não explica nada sozinho.
- **O retorno é maior justamente onde a adoção é menor.** Economia anual por kWp instalado: Nordeste R$ 1.216 contra Sul R$ 1.039. A barreira não é a viabilidade do painel, é o acesso ao investimento inicial.
- **O mercado é concentrado.** 10% dos municípios concentram 58,8% da potência. 29% da potência é de fazendas solares de autoconsumo remoto, ou seja, investimento de quem já tem capital.
- **Nas grandes cidades, a moradia vertical também pesa.** Salvador (28% de apartamentos) tem 7 telhados solares por mil domicílios, quando o esperado pelo seu perfil seria 22.

2. Situações, regiões e grupos que merecem atenção

1. **Perfil "Muito sol, baixa renda":** 1.676 municípios e 48,4 milhões de pessoas, 88% no Nordeste. Irradiação de 5,48 kWh/m²/dia (a maior), PIB per capita de R$ 15 mil e só 141 W por habitante. Metade da potência instalada nesses municípios é de autoconsumo remoto, isto é, geração cujo crédito vai para consumidores de outros lugares.
2. **Capitais e regiões metropolitanas do Nordeste com maior lacuna:** Salvador (14,4 mil telhados abaixo do esperado), Jaboatão dos Guararapes (4,2 mil), Caucaia (3,5 mil) e Recife.
3. **Perfil "Urbanos de baixa adoção":** 899 municípios e 75,6 milhões de pessoas no litoral e nas regiões metropolitanas do Sudeste e do Norte, com 139 W por habitante.
4. **Estados com menor adoção por habitante:** AM (115 W/hab), RJ (130), SE (147), PB e MA (167).

3. Padrões e tendências

- **Ciclo regulatório:** a corrida de 2022 (8,9 GW) antes da Lei 14.300, a queda em 2023 e o recorde de 2024 (10,6 GW). Em 2025 o mercado estabilizou (9,8 GW).

- **O Nordeste é a única região em crescimento:** nos últimos 12 meses estáveis (jun/25 a mai/26), a potência conectada no Nordeste cresceu 12,4%, enquanto o Brasil caiu 2,3%. Paraíba (+54%) e Bahia (+32%) lideram. O mercado do Nordeste está começando a responder, e esse é o momento de política pública ter maior efeito por real investido.
- **Agro e Centro-Oeste lideram por habitante:** MT (872 W/hab) e MS (699) têm a maior adoção, puxada por propriedades rurais, que concentram 44% da potência no perfil "Agro solar".

4. Decisões recomendadas

#	Decisão	Onde	Evidência
1	**Crédito solar com juros subsidiados e prazo compatível com a economia mensal** (a parcela cabe na conta de luz que deixa de ser paga)	1.676 municípios do perfil "Muito sol, baixa renda", começando pelos de maior lacuna	Renda é o principal fator. O retorno por kWp é o mais alto do país
2	**Geração compartilhada e cooperativas solares** para quem não tem telhado próprio	Capitais com alta verticalização e lacuna: Salvador, Recife, Belo Horizonte, São Paulo	Lacuna concentrada em cidades com 28% a 39% de apartamentos
3	**Painéis solares em habitação social** (Minha Casa Minha Vida) e em prédios públicos com crédito revertido a famílias de baixa renda	Nordeste e perfil "Urbanos de baixa adoção"	Baixa renda é 1,3% dos sistemas residenciais registrados
4	**Exigir que as distribuidoras registrem a classe baixa renda** no cadastro de geração distribuída	ANEEL, todas as 102 distribuidoras (só 27 registram hoje)	Sem esse dado, não é possível medir se a política chega a quem precisa
5	**Usar o ranking de lacuna da camada Gold** como critério de priorização de municípios em editais	Tabela `gold/lacuna_adocao`	Compara cada município com outros de perfil semelhante

5. Resultados a acompanhar

Indicador	Linha de base	Meta sugerida (3 anos)	Fonte
Telhados solares por mil domicílios no Nordeste	30	45 (metade da distância para o Centro-Oeste)	ANEEL + IBGE
Participação do Nordeste na potência nova dos últimos 12 meses	26%	igual à participação na população (27%)	ANEEL
W por habitante no perfil "Muito sol, baixa renda"	141	250	ANEEL + IBGE
Telhados residenciais abaixo do esperado	373 mil	redução de 30%	modelo da camada Gold
Distribuidoras que registram baixa renda	27 de 102	102 de 102	ANEEL
Sistemas de baixa renda no total residencial	1,3%	5%	ANEEL

O pipeline é reexecutável todo mês com a nova base da ANEEL. Os indicadores acima são atualizados automaticamente e podem alimentar um painel de acompanhamento da política.

Limitações

O PIB per capita é uma aproximação de renda das famílias. A data de conexão da ANEEL é a data da última atualização cadastral. Os últimos meses da base têm atraso de registro (tratado com corte automático). A classificação de baixa renda é subnotificada. O modelo de lacuna serve para priorizar, não como meta exata por município.

Referências

AGÊNCIA NACIONAL DE ENERGIA ELÉTRICA (ANEEL). **Relação de empreendimentos de geração distribuída**. Brasília: ANEEL, 2026. Conjunto de dados abertos. Disponível em: https://dadosabertos.aneel.gov.br/dataset/relacao-de-empreendimentos-de-geracao-distribuida. Acesso em: 9 nov. 2026.

AGÊNCIA NACIONAL DE ENERGIA ELÉTRICA (ANEEL). **Resolução Normativa nº 1.000, de 7 de dezembro de 2021**. Estabelece as Regras de Prestação do Serviço Público de Distribuição de Energia Elétrica. Brasília: ANEEL, 2021. Disponível em: https://www2.aneel.gov.br/cedoc/ren20211000.html. Acesso em: 9 nov. 2026.

AGÊNCIA NACIONAL DE ENERGIA ELÉTRICA (ANEEL). **Tarifas homologadas das distribuidoras de energia elétrica**. Brasília: ANEEL, 2026. Conjunto de dados abertos. Disponível em: https://dadosabertos.aneel.gov.br/dataset/tarifas-distribuidoras-energia-eletrica. Acesso em: 9 nov. 2026.

ARMBRUST, M. *et al*. Delta Lake: high-performance ACID table storage over cloud object stores. **Proceedings of the VLDB Endowment**, v. 13, n. 12, p. 3411-3424, 2020. DOI: https://doi.org/10.14778/3415478.3415560.

BRASIL. **Lei nº 13.709, de 14 de agosto de 2018**. Lei Geral de Proteção de Dados Pessoais (LGPD). Brasília, DF: Presidência da República, 2018. Disponível em: https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm. Acesso em: 9 nov. 2026.

BRASIL. **Lei nº 14.300, de 6 de janeiro de 2022**. Institui o marco legal da microgeração e minigeração distribuída e o Sistema de Compensação de Energia Elétrica. Brasília, DF: Presidência da República, 2022. Disponível em: https://www.planalto.gov.br/ccivil_03/_ato2019-2022/2022/lei/l14300.htm. Acesso em: 9 nov. 2026.

BREIMAN, L. Random forests. **Machine Learning**, v. 45, n. 1, p. 5-32, 2001. DOI: https://doi.org/10.1023/A:1010933404324.

DATABRICKS. **Lineage in Unity Catalog**. Databricks Documentation, 2026. Disponível em: https://docs.databricks.com/aws/en/data-governance/unity-catalog/data-lineage. Acesso em: 9 nov. 2026.

DATABRICKS. **What is the medallion lakehouse architecture?** Databricks Documentation, 2026. Disponível em: https://docs.databricks.com/aws/en/lakehouse/medallion. Acesso em: 9 nov. 2026.

FRIEDMAN, J. H. Greedy function approximation: a gradient boosting machine. **The Annals of Statistics**, v. 29, n. 5, p. 1189-1232, 2001. DOI: https://doi.org/10.1214/aos/1013203451.

INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA (IBGE). **API de Localidades**. Rio de Janeiro: IBGE, 2026. Disponível em: https://servicodados.ibge.gov.br/api/docs/localidades. Acesso em: 9 nov. 2026.

INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA (IBGE). **Censo Demográfico 2022**: tabelas 4712, 4714 e 6326. Sistema IBGE de Recuperação Automática (SIDRA). Rio de Janeiro: IBGE, 2026. Disponível em: https://sidra.ibge.gov.br/tabela/4714. Acesso em: 9 nov. 2026.

INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA (IBGE). **Produto Interno Bruto dos Municípios 2023**: tabela 5938. Sistema IBGE de Recuperação Automática (SIDRA). Rio de Janeiro: IBGE, 2026. Disponível em: https://sidra.ibge.gov.br/tabela/5938. Acesso em: 9 nov. 2026.

PEDREGOSA, F. *et al*. Scikit-learn: machine learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825-2830, 2011. Disponível em: https://jmlr.org/papers/v12/pedregosa11a.html. Acesso em: 9 nov. 2026.

PEREIRA, E. B. *et al*. **Atlas brasileiro de energia solar**. 2. ed. São José dos Campos: INPE, 2017. DOI: https://doi.org/10.34024/978851700089. Dados disponíveis em: https://labren.ccst.inpe.br/atlas_2017.html. Acesso em: 9 nov. 2026.

RAASVELDT, M.; MÜHLEISEN, H. DuckDB: an embeddable analytical database. *In*: INTERNATIONAL CONFERENCE ON MANAGEMENT OF DATA (SIGMOD), 2019, Amsterdam. **Proceedings** [...]. New York: ACM, 2019. p. 1981-1984. DOI: https://doi.org/10.1145/3299869.3320212.

ROUSSEEUW, P. J. Silhouettes: a graphical aid to the interpretation and validation of cluster analysis. **Journal of Computational and Applied Mathematics**, v. 20, p. 53-65, 1987. DOI: https://doi.org/10.1016/0377-0427(87)90125-7.

SPEARMAN, C. The proof and measurement of association between two things. **The American Journal of Psychology**, v. 15, n. 1, p. 72-101, 1904. DOI: https://doi.org/10.2307/1412159.

ZAHARIA, M. *et al*. Apache Spark: a unified engine for big data processing. **Communications of the ACM**, v. 59, n. 11, p. 56-65, 2016. DOI: https://doi.org/10.1145/2934664.